

Psychoanaliza LLM

Warsztaty badawcze 2

Semestr 6

Autorzy:

Paweł Florek, Paweł Pozorski, Hubert Sobociński

Wydział Matematyki i Nauk Informatycznych

Politechnika Warszawska

20 maja 2025

Spis treści

1	Wstęp	2
1.1	Pytanie badawcze	2
1.2	Teza badawcza	2
2	Przeprowadzony eksperyment	2
2.1	Użyte modele	2
2.2	Zbiór danych	3
2.3	Koncepcje psychologiczne	3
2.4	Prompt	3
2.5	Napotkane problemy	4
2.6	Cel i opis eksperymentu	4
3	Wyniki eksperymentu	4
4	Future works	9

1 Wstęp

Przyspieszony rozwój dużych modeli językowych (LLM) w ciągu ostatnich kilku lat otworzył nowe możliwości badania zdolności takich modeli do symulowania wyższych aspektów ludzkiego funkcjonowania. Jednym z ważnych kierunków takich badań jest sprawdzenie, w jakim stopniu takie modele mogą replikować ludzkie zachowania psychologiczne - w sposób spójny, powtarzalny i zgodny z ustaleniami psychometrii. Poniższe badanie było inspirowane pracą Petrova, Serapio-Garcí i Rentfrowa (2024), w której autorzy przetestowali modele LLM pod kątem ich zdolności psychologicznych przy użyciu standardowych narzędzi diagnostycznych.

Jeśli LLM-y potrafiłyby wiernie symulować profile psychologiczne ludzi, mogłyby stać się bardzo przydatnym narzędziem w badaniach społecznych, pozwalając na przeprowadzanie wstępnych eksperymentów za ułamek kosztów tradycyjnych badań. Mogłyby także dostarczać dodatkowych dowodów potwierdzających konkretne hipotezy (jeżeli model daje taki sam wynik jak ludzie to mam większą pewność) i umożliwiać analizowanie trudnych do uzyskania zestawów danych. Jednym z najbardziej istotnych zastosowań LLM-ów byłoby tworzenie symulacji opartej na agentach, modelujących różne środowiska, takie jak media społecznościowe, organizacje lub większe społeczności. Takie symulacje mogłyby działać jako „piaskownice behawioralne”, w których można testować wpływ różnych algorytmów, polityk krajowych czy różnych systemów przed ich wdrożeniem.

W naszym badaniu poszliśmy o krok dalej i porównaliśmy odpowiedzi sześciu różnych modeli językowych z wybranymi kwestionariuszami psychometrycznymi. Dane zostały zebrane z zestawu sztucznych profili osób, dzięki czemu możliwe było kontrolowanie symulacji różnych odpowiedzi. Wykorzystano innych danych względem tych użytych w przywołanym artykule, aby zbadać czy miały one wpływ na jakość odpowiedzi. Po uzyskaniu wyników zostały one zintegrowane i przeprowadzono analizę, umożliwiając ocenę modeli i bliskości do ludzkich wzorców odpowiedzi.

W kolejnych sekcjach przedstawiamy metodologię krok po kroku, wyniki i ich omówienie w kontekście potencjału modeli językowych do symulacji procesów psychologicznych.

1.1 Pytanie badawcze

Przed przeprowadzeniem badań postawiliśmy dwa badania badawcze, wzorując się na oryginalnym artykule. Jakie wyniki duże modele językowe osiągają w testach psychologicznych? Czy pochodzenie dużego modelu językowego wpływa na jego wyniki w testach psychologicznych?

1.2 Teza badawcza

Modele osiągną słabe wyniki w testach psychologicznych, co potwierdzi ich niezdolność do odzworowywania ludzkich zachowań psychologicznych. Pochodzenie modelu wpływa na wyniki uzyskiwane w testach psychologicznych. Różne modele mogą przejawiać odmienny profil cech psychologicznych, odzwierciedlający różnice w ich konstrukcji i źródłach danych.

2 Przeprowadzony eksperyment

2.1 Użyte modele

W przeprowadzonych badaniach użyto następujących modeli:

- Aya 23 8B - model firmy AYA AI. Został wytrenowany na różnorodnych danych wielojęzycznych open-source z naciskiem na inkluzywność językową (ponad 50 języków). Złożony z Decoder-only Transformer z mechanizmem Multi-Query Attention (MQA).
- Granite 3.3 8B Instruct - model firmy IBM. Model koncentruje się na języku angielskim z naciskiem na zastosowania korporacyjne i zadania wymagające precyzyjnego rozumienia instrukcji. Złożony z transformerów z Grouped-Query Attention (GQA)
- Internlm 3 8B Instruct - chiński model opracowany przez Shanghai AI Laboratory. Model został wytrenowany na danych zarówno chińskich jak i angielskich. Wykorzystano (MQA).

- **Minstral 8B Instruct** - francuski model firmy Mistral AI. Bazuje na architekturze Transformer, ale wprowadza efektywne mechanizmy uwagi, takie jak Sliding Window Attention.
- **Qwen 3 8B Instruct** - chiński model opracowany przez Alibaba Cloud. Wykorzystuje GQA.
- **Llama 3.1 8B Instruct** - model firmy Meta AI. Model skupiony na języku angielskim. Wykorzystuje Decoder-only Transformer z GQA

Wybrane modele różnią się pod względem pochodzenia, architektury oraz obsługują różne języki. Posiadają one ten sam rozmiar, aby wyeliminować jego wpływ na jakość odpowiedzi. Wszystkie modele są open-source i były uruchamiane lokalnie poprzez aplikację LM Studio.

2.2 Zbiór danych

Adresując propozycję autorów, zmieniliśmy dane opisów osób na dane bardziej opisowe. Wykorzystaliśmy bazę PersonaHub oraz zbiór elite persona. Składa się ona z syntetycznych profili osób zaprojektowanych w celu odzwierciedlenia realistycznych ról społecznych i zawodowych. Każdy opis zawiera informacje dotyczące zakresu obowiązków, środowiska zawodowego, specjalizacji tematycznej oraz potencjalnych doświadczeń osobistych i zawodowych.

2.3 Koncepcje psychologiczne

W pracy wykorzystano koncepcje psychologiczne związane z cechami osobowości, agresją, afektem oraz samokontrolą. Będą to:

Model Wielkiej Piątki (BFI) odnoszący się do koncepcji pięciu podstawowych wymiarów osobowości: neurotyczności, ekstrawersji, otwartości na doświadczenie, ugodowości i sumienności.

Kwestionariusz Agresji (BPAQ) bazujący na koncepcji agresji jako wielowymiarowego zjawiska obejmującego agresję fizyczną, werbalną, wrogość i gniew.

Kwestionariusz PANAS opierający się na teorii emocji, mierząc pozytywne i negatywne stany afektywne.

Skala Samokontroli SSCS nawiązująca do koncepcji samokontroli jako zdolności do regulowania impulsów i zachowań zgodnie z długoterminowymi celami.

Odpowiedzi na pytania z kwestionariuszy będą w skali 1-5. Udzielone odpowiedzi zostaną wykorzystane do późniejszej analizy.

2.4 Prompt

W celu uzyskania odpowiedzi modeli na pytania psychometryczne zastosowano ujednolicony prompt, zawierający opis osobowości, instrukcję zadania oraz szczegółowy format odpowiedzi. Treść promptu prezentuje się następująco:

```
Your personality
{persona_description}

# Task
Answer each psychological questionnaire question based on the personality description above.

# Response format
- You MUST respond with EXACTLY ONE number from 1-5 for each question
- Provide ONLY a JSON array with numbers: {"answers": [1, 2, 3, ...]}
```

```
# Questions (Batch {batch_num})
{questions}
```

Return only the JSON object in the format: {"answers": [n, n, n, ...]}
where n is a number from 1-5.

Kwestionariusze zostały podzielone na partie (batche), ponieważ modele miały trudności z poprawnym odpowiadaniem na zbyt długie listy pytań w jednym przebiegu.

2.5 Napotkane problemy

W trakcie realizacji badań napotkano kilka istotnych trudności. Przede wszystkim, ze względu na ograniczone zasoby obliczeniowe oraz pieniężnych, ograniczono się do korzystania z darmowych modeli językowych o rozmiarze do 8 miliardów parametrów, możliwych do uruchomienia lokalnie. Pomimo niewielkiego rozmiaru modeli, czas generowania odpowiedzi okazał się bardzo długi. W związku z tym proces zbierania odpowiedzi pozostaje otwarty i będzie kontynuowany aż do osiągnięcia założonej liczby odpowiedzi.

Dodatkową komplikacją był sposób działania aplikacji LM Studio, za pośrednictwem której uruchamiano modele. Z nieznanych przyczyn modele nie wykorzystywały pełnej mocy obliczeniowej GPU, opierając się głównie na CPU, co znacząco wpłynęło na wydajność. Pomimo prób rozwiązania tego problemu, nie udało się wymusić pełnego wykorzystania akceleracji sprzętowej.

Kolejnym problemem była ograniczona zdolność modeli do generowania poprawnych i spójnych odpowiedzi przy zbyt dużej liczbie pytań zadanych jednocześnie. Aby temu przeciwdziałać, zastosowano podział kwestionariuszy na mniejsze partie (batche), co pozwoliło utrzymać jakość i zgodność odpowiedzi z wymaganym formatem.

2.6 Cel i opis eksperymentu

Celem przeprowadzonego eksperymentu było zebranie odpowiedzi dużych modeli językowych na wybrane kwestionariusze psychologiczne, a następnie analiza tych odpowiedzi pod kątem ich psychometrycznej poprawności oraz podobieństwa do wyników uzyskiwanych przez ludzi.

Do eksperymentu losowo wybrano zbiór profili osobowości (person), pochodzących z zestawu PersonaHub: Elite Persona. Dla każdego z nich, przy użyciu wcześniej opisanego prompta, generowano odpowiedzi na pytania kwestionariuszy.

Na podstawie uzyskanych danych obliczono podstawowe wskaźniki rzetelności psychometrycznej: alfa Cronbacha, Greatest Lower Bound (GLB) oraz omega McDonalda.


Dodatkowo, przeanalizowano korelacje między odpowiedziami udzielonymi przez modele a danymi referencyjnymi uzyskanymi od ludzi. W tym celu wyznaczono współczynniki korelacji Pearsona oraz przeprowadzono analizę rozkładu odpowiedzi modeli.

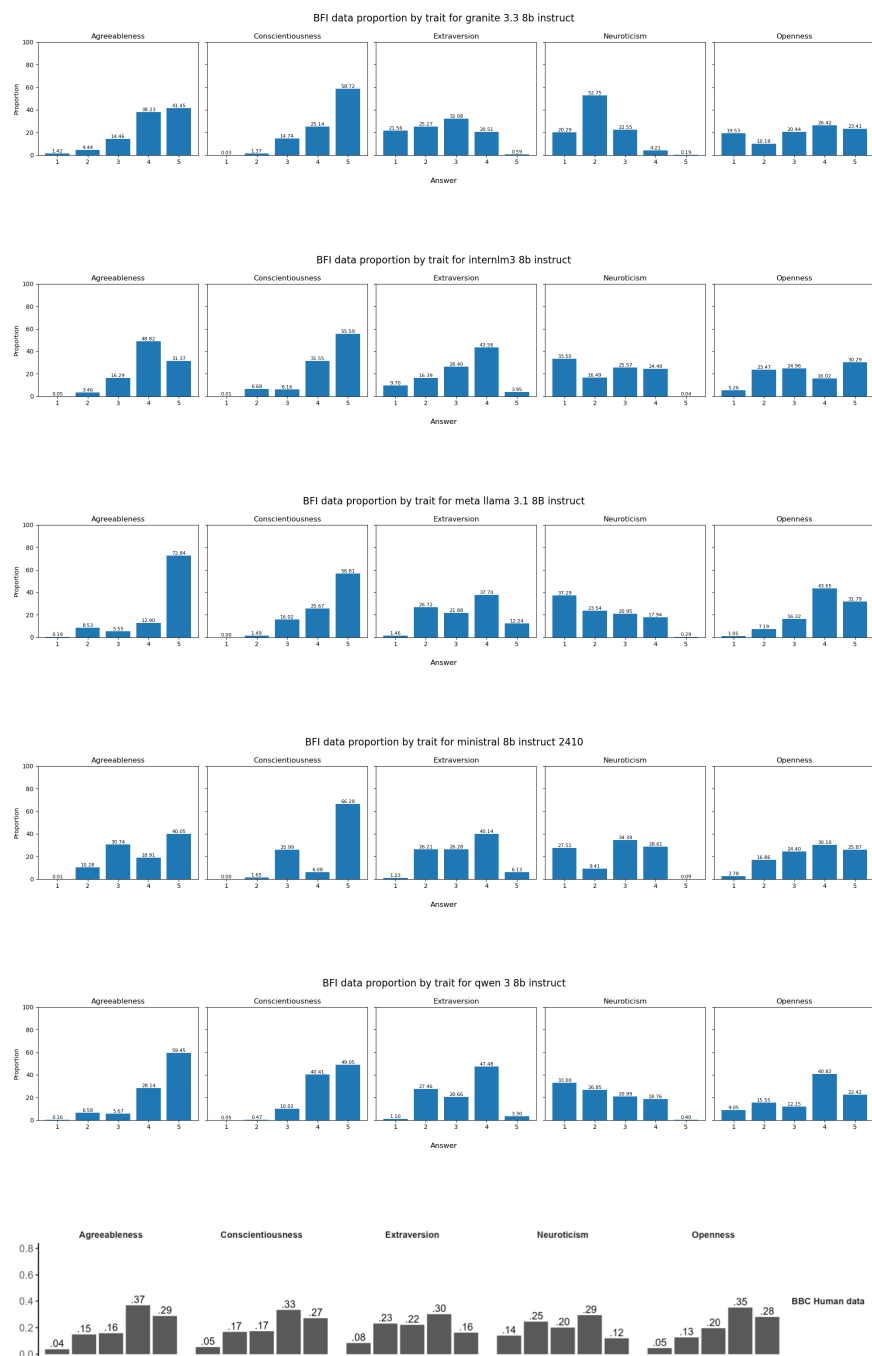
Wybrano taki cel by przetestować LLM w tego typu testach, a następnie przeanalizować wyniki pod kątem zdolności do odwzorowywania

3 Wyniki eksperymentu

Wyniki naszego eksperymentu będziemy porównywać z wynikami ludzkimi oraz modeli autorów przytaczanego artykułu, których wykresy są zaczerpnięte z artykułu. W wynikach skupimy się na BFI z uwagi na to, że był głównie wykorzystany w artykule i będziemy mieli oczywiste porównanie wyników obu eksperymentów.

Przeanalizujemy na początek dystrybucje odpowiedzi modeli dla poszczególnych kwestionariuszy i cech. Porównanie wyników modeli dla kwestionariusza BFI oraz ludzkich odpowiedzi przedstawia się następująco:









Rysunek 1: Wyniki twórców


Zauważyć można różne dystrybucje w przypadku różnych modeli. Pare modeli ma podobny rozkład w tych samym atrybutach, jednak brak takich, które w każdym atrybucie miałyby taki sam rozkład odpowiedzi.

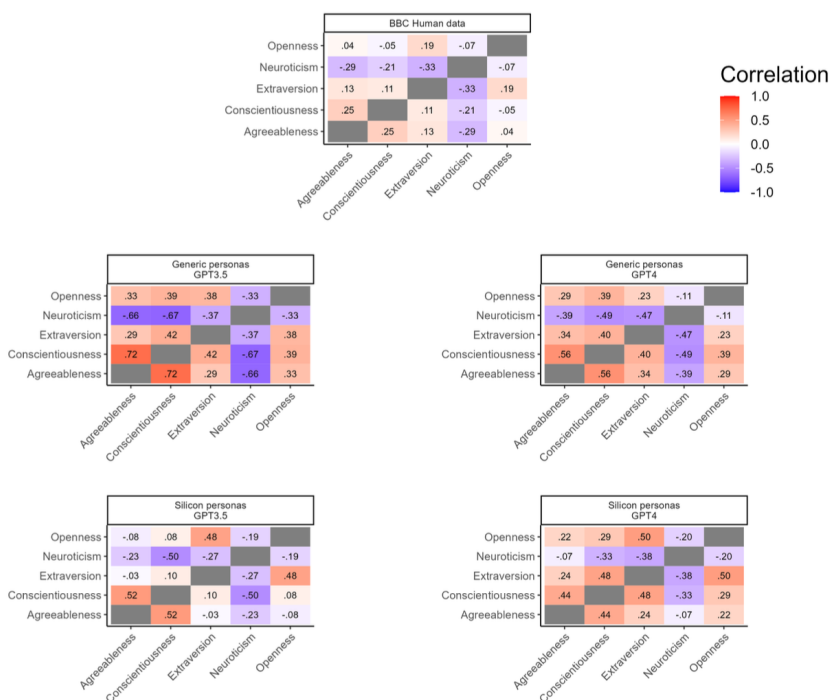
Porównując z odpowiedziami ludzi, ciężko o podobieństwo i w przeważającej większości dystrybucje bardzo różnią się.

Ważną kwestią jest porównanie korelacji odpowiedzi dla atrybutów na tle korelacji w odpowiedziach ludzi. Pokaże to, czy modele są wyuczone zależności, które nie występują w rzeczywistości.









Rysunek 2: Wyniki twórców

W niektórych modelach (np. Llama) występują korelacje pomiędzy neurotyzmem a innymi cechami, tak samo jak w przypadku przytaczanego artykułu. W paru innych pojawiły się korelacje związane z cechą sumienności, która nie występowała wcześniej.

4 Future works

W najbliższych tygodniach planowane jest zwiększenie liczby zgromadzonych odpowiedzi oraz rozszerzenie danych wejściowych o elementy interakcji między personami, realizowane w formie dialogów. Taki zabieg mógłby wprowadzić dodatkową warstwę emocjonalną oraz złożoność psychospołeczną do opisów, co potencjalnie wpłynęłoby na bardziej realistyczne i wielowymiarowe zachowania generowane przez modele. Dodatkowo zakładane jest przygotowanie artykułu naukowego podsumowującego wyniki przeprowadzonych badań. Proces tworzenia publikacji będzie prowadzony zespołowo, angażując wszystkich członków zespołu.

W ramach dalszych badań proponujemy wykorzystanie bardziej zaawansowanych modeli językowych dostępnych na rynku oraz zastosowanie wydajniejszego sprzętu obliczeniowego. Pozwoli to na poprawę jakości generowanych odpowiedzi oraz znaczące skrócenie czasu ich pozyskiwania, co z kolei umożliwi zwiększenie wielkości próby badawczej.